

# Aprendizaje Automático y Minería de Datos

## Regresión lineal


Cristina Tîrnăucă

Dept. Matesco, Universidad de Cantabria

Fac. Ciencias – Grado en Ing. Informática

# Regresión lineal univariante

Estimación por mínimos cuadrados ordinarios



# Datos de entrada y notación

Datos de entrenamiento:

Superficie en $m^2$ ( $x$ )	Precio en euros ( $y$ )
88	210000
90	230000
47	95000
111	230000
...	...

**Tabla:** Precio (en euros) según superficie (en metros cuadrados)

Notación:

$m$  = número de ejemplos

$x$  = variable de entrada (superficie),  $x^{(i)}$

$y$  = variable de salida (precio),  $y^{(i)}$

Objetivo: hallar una recta que mejor **se aproxime** a los datos.

# Método iterativo

## Algoritmo del gradiente descendente, I

Objetivo: hallar  $h(x) = \theta_0 + \theta_1 * x$

Bajo condición: el coste  $J(\theta_0, \theta_1) = \text{mínimo}$ , donde

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

# Método iterativo

## Algoritmo del gradiente descendente, I

Objetivo: hallar  $h(x) = \theta_0 + \theta_1 * x$

Bajo condición: el coste  $J(\theta_0, \theta_1) = \text{mínimo}$ , donde

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

Idea:

- ▶ Empezar con  $\theta_0$  y  $\theta_1$  al azar
- ▶ Modificar  $\theta_0$  y  $\theta_1$  para reducir  $J(\theta_0, \theta_1)$  hasta que (eventualmente) lleguemos a un mínimo.

# Método iterativo

## Algoritmo del gradiente descendente, II

Idea:

- ▶ Empezar con  $\theta_0$  y  $\theta_1$  al azar
- ▶ Modificar  $\theta_0$  y  $\theta_1$  para reducir  $J(\theta_0, \theta_1)$  hasta que (eventualmente) lleguemos a un mínimo.

repetir hasta convergencia {

$$\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

(para  $j = 0$  y  $j = 1$ )

}

$\alpha$  = ratio de aprendizaje

Modelo de regresión lineal:

$$h(x) = \theta_0 + \theta_1 * x$$

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

# Método iterativo

## Algoritmo del gradiente descendente, III

repetir hasta convergencia {

$$\theta_0 = \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\theta_1 = \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

}

$\alpha$  = ratio de aprendizaje

# Método iterativo

## Algoritmo del gradiente descendente, III

repetir hasta convergencia {  
     $\theta_0 = \theta_0 - \alpha \frac{\partial}{\partial \theta_0} \left( \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 \right)$   
     $\theta_1 = \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$   
}

$\alpha$  = ratio de aprendizaje



# Método iterativo

## Algoritmo del gradiente descendente, III

repetir hasta convergencia {  
     $\theta_0 = \theta_0 - \alpha \frac{\partial}{\partial \theta_0} (\frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2)$   
     $\theta_1 = \theta_1 - \alpha \frac{\partial}{\partial \theta_1} (\frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2)$   
}

$\alpha$  = ratio de aprendizaje

# Método iterativo

## Algoritmo del gradiente descendente, III

repetir hasta convergencia {  
     $\theta_0 = \theta_0 - \alpha \frac{\partial}{\partial \theta_0} (\frac{1}{2m} \sum_{i=1}^m (\theta_0 + \theta_1 * x^{(i)} - y^{(i)})^2)$   
     $\theta_1 = \theta_1 - \alpha \frac{\partial}{\partial \theta_1} (\frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2)$   
}

$\alpha$  = ratio de aprendizaje

# Método iterativo

## Algoritmo del gradiente descendente, III

repetir hasta convergencia {  
     $\theta_0 = \theta_0 - \alpha \frac{\partial}{\partial \theta_0} \left( \frac{1}{2m} \sum_{i=1}^m (\theta_0 + \theta_1 * x^{(i)} - y^{(i)})^2 \right)$   
     $\theta_1 = \theta_1 - \alpha \frac{\partial}{\partial \theta_1} \left( \frac{1}{2m} \sum_{i=1}^m (\theta_0 + \theta_1 * x^{(i)} - y^{(i)})^2 \right)$   
}  
 $\alpha =$  ratio de aprendizaje

# Método iterativo

## Algoritmo del gradiente descendente, III

repetir hasta convergencia {

$$\theta_0 = \theta_0 - \alpha \left( \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 * x^{(i)} - y^{(i)}) * 1 \right)$$

$$\theta_1 = \theta_1 - \alpha \frac{\partial}{\partial \theta_1} \left( \frac{1}{2m} \sum_{i=1}^m (\theta_0 + \theta_1 * x^{(i)} - y^{(i)})^2 \right)$$

}

$\alpha$  = ratio de aprendizaje

# Método iterativo

## Algoritmo del gradiente descendente, III

repetir hasta convergencia {

$$\theta_0 = \theta_0 - \alpha \left( \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 * x^{(i)} - y^{(i)}) * 1 \right)$$

$$\theta_1 = \theta_1 - \alpha \left( \frac{1}{m} \sum_{i=1}^m (\theta_0 + \theta_1 * x^{(i)} - y^{(i)}) * x^{(i)} \right)$$


}

$\alpha$  = ratio de aprendizaje


# Función de coste - intuiciones, I

Modelo simplificado:  $\theta_0 = 0$

$$h(x)$$




$$J(\theta_1)$$




# Función de coste - intuiciones, II

Modelo general:  $\theta_0$  arbitrario

$$h(x)$$



$$J(\theta_0, \theta_1)$$



# Función de coste - intuiciones, II

El ratio de aprendizaje  $\alpha$

$$\theta_1 = \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$

$\alpha$  muy pequeño: el algoritmo tarda mucho en converger

$\alpha$  muy grande: el algoritmo no converge



# Función de coste - intuiciones, II

El ratio de aprendizaje  $\alpha$

$$\theta_1 = \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$


$\alpha$  muy pequeño: el algoritmo tarda mucho en converger

$\alpha$  muy grande: el algoritmo no converge

El algoritmo puede converger a un mínimo local incluso cuando  $\alpha$  es fijo.


# Función de coste - intuiciones, III

Mínimo local / global



# Función de coste - intuiciones, IV

Mínimo local / global



# Método analítico

Objetivo: hallar  $h(x) = \theta_0 + \theta_1 * x$

Bajo condición: el coste  $J(\theta_0, \theta_1) = \text{mínimo}$ , donde

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

# Método analítico

Objetivo: hallar  $h(x) = \theta_0 + \theta_1 * x$

Bajo condición: el coste  $J(\theta_0, \theta_1) = \text{mínimo}$ , donde

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

Solución analítica:

$$\theta_0 = \frac{\sum_{i=1}^m x^{(i)} * \sum_{i=1}^m x^{(i)} y^{(i)} - \sum_{i=1}^m x^{(i)} x^{(i)} * \sum_{i=1}^m y^{(i)}}{\sum_{i=1}^m x^{(i)} * \sum_{i=1}^m x^{(i)} - m \sum_{i=1}^m x^{(i)} x^{(i)}}$$

$$\theta_1 = \frac{\sum_{i=1}^m x^{(i)} * \sum_{i=1}^m y^{(i)} - m \sum_{i=1}^m x^{(i)} y^{(i)}}{\sum_{i=1}^m x^{(i)} * \sum_{i=1}^m x^{(i)} - m \sum_{i=1}^m x^{(i)} x^{(i)}}$$